

시간대별 OD 데이터로 본 서울 수도권 이동의 잠재 동기

한수민

한국과학영재학교 (Korea Science Academy of KAIST)
suminhan@ksa.kaist.ac.kr

초안 2026년 10월

초록

통신 기록에 기반한 생활이동 데이터는 행정동 사이 시간대별 이동량을 촘촘히 제공하지만, 사람들이 왜 움직였는지는 직접 보여주지 않는다. 본 연구는 서울시·KT 수도권 생활이동 데이터(2024년, 노드 481개)를 소수의 잠재 이동 동기가 만들어낸 흐름으로 분해하는 푸아송 모델을 제안한다. 각 동기는 출발지 분포, 도착지 분포, 평일·주말별 하루 리듬, 거리 감쇠 척도를 갖는다. 학습에는 이동량만 쓰고, 데이터에 이미 들어 있는 이동 목적·내외국인·이동거리 라벨은 평가에만 쓴다. 평가는 사전에 적어둔 여섯 가지 가설(예상과 이유 포함)에 대해 숨겨둔 라벨, 생활이동과 무관한 교통카드·도로 센서, 실제 사건일, 다른 연도로 수행했다. 동기 6개(파라미터 6천 개)만으로 46만 파라미터의 정적 OD 모델과 같은 검증 편차에 도달하며, 8개에서는 12% 낮다. 동기마다 하루 리듬이 달라야 한다는 점은 리듬을 공유시키면 편차가 47% 악화되는 것으로 확인된다. 통근 동기의 일별 세기는 교통카드 지하철 승하차의 같은 요일 잔차와 0.66–0.77의 상관을 보이고, 불꽃축제와 여의도 집회가 있던 날에는 모델이 설명하지 못하는 초과 도착이 여의동에 +44%–+56% 집중된다(평범한 토요일은 –23%, –32%). 반면 숨겨둔 목적 라벨의 복원은 시간대만 쓴 예측을 소폭(+1.6%p)만 넘었고, 단기외국인 동기는 분리되지 않았다. 단기외국인의 시간대별 흐름이 내국인과 사실상 같기(상관 0.976) 때문이다. 부수적으로 2023–2026년 서울 출근 거리는 늘지 않았다(평균 11.11 km에서 10.88 km). 예상이 빗나간 항목과 분석 중 발견해 정정한 오류도 함께 보고한다.

키워드: 생활이동, OD 행렬, 잠재 동기, 푸아송 분해, 통신 데이터, 외부 검증

1 서론

이동 데이터는 풍부해졌지만 이동의 이유는 여전히 관측하기 어렵다. 가구통행실태조사 같은 설문은 목적을 직접 묻지만 몇 해에 한 번만 이루어지고 표본이 작다. 통신 기반 이동 데이터는 매일 도시 전체를 덮지만 목적은 제공자가 규칙으로 추정된 값이다. 이 글은 반대 방향에서 묻는다. 목적 라벨 없이, 흐름의 패턴만으로 이동을 만들어내는 숨은 동기를 추정할 수 있는가. 그리고 추정한 동기가 모델이 한 번도 보지 못한 정보와 맞는가.

접근은 다음과 같다. 각 시간대의 행정동 사이 이동량을 소수의 동기가 합쳐진 결과로 보고, 동기마다 “어디서 출발하기 쉽고, 어디로 가기 쉽고, 몇 시에 일어나기 쉽고, 얼마나 먼 곳까지 가는가”를 매개변수로 둔다. 이 매개변수들은 모두 사람이 읽을 수 있다. 학습이 끝난 뒤에는

(i) 데이터에 있지만 학습에 쓰지 않은 목적·국적 라벨, (ii) 생활이동과 측정 방식이 완전히 다른 교통카드·도로 검지기, (iii) 날짜가 알려진 사건, (iv) 다른 연도의 데이터로 모델을 시험한다.

이 연구는 평가 항목을 학습 전에 정했고, 각 가설에 예상과 그 이유를 함께 적었다(3.4절). 결과는 예상 대비로 보고하며, 맞은 것과 틀린 것을 구분한다. 맞은 가설만 골라 쓰지 않기 위해서다.

기여. (1) 라벨을 학습이 아닌 평가에만 쓰는 잠재 동기 분해와 외부 검증 틀을 제시한다. (2) 서울 수도권 2024년 데이터에서 동기가 성립하는 범위와 성립하지 않는 범위를 정량적으로 보인다. (3) 사용한 데이터의 구조적 문제(인코딩 변경, 행정구역 코드 변경, 라벨의 행동적 의미)와 분석 중 발견해 고친 오류를 기록한다. (4) 같은 데이터에서 얻은 부수적 관측, 곧 2023–2026년 출근 거리 추이와 단기외국인 라벨의 성격을 보고한다.

2 관련 연구

이동성과 통신 기반 OD. 개인 이동은 규칙성이 강하고 소수의 장소에 집중된다는 것이 휴대전화 기록으로 보고되었다 [4]. 통신 기록으로 OD 흐름을 추정하는 방법은 [3]에서, 이동 목적과 시간대를 통신 데이터에서 추정하는 방법은 [1]에서 다루어졌고, 설문 없이 이동 행동을 생성하는 틀은 [6]에서 제안되었다. 도시의 공간 구조를 통신 데이터에서 읽는 연구는 [8]에 있다. 본 연구가 쓰는 목적 라벨은 이런 추정의 산물이므로, 라벨을 정답이 아닌 비교 대상으로 다룬다.

공간 상호작용과 분해 모형. 이동량을 출발지와 도착지의 크기와 거리 감쇠로 설명하는 중력형 모형은 오래된 전통이 있다 [10, 9]. 비음수 행렬 분해 [7]와 잠재 토픽 모형 [2]은 관측된 합을 소수의 부분 구조로 나누는 방법이다. 본 모델은 이 둘을 결합해, 동기마다 중력형 공간 구조와 하루 리듬을 갖게 한 푸아송 분해로 볼 수 있다.

선행 연구와의 관계. 저자는 선행 연구에서 서울 생활인구를 잠재 벡터로 압축한 도시 활력 임베딩을 다루었다 [5]. 본 연구는 같은 데이터군의 이동(흐름) 쪽을 다루며, 하루 패턴 자동인코딩 임베딩이 평균 프로파일을 넘지 못했던 예비 실험(5.10절)에서 방향을 바꾼 것이다.

3 데이터

3.1 수도권 생활이동

서울시와 KT가 공개한 “수도권 생활이동” 가운데 출발·도착 행정동별 이동 데이터(서울 열린데이터광장 OA-22300)를 쓴다. 일별 파일에 출발·도착 행정동, 출발 시각, 내/외국인 구분, 이동 목적, 평균 이동거리와 시간, 이동 인구수가 들어 있다. 기간은 2023-01-01부터 2026-08-31까지 1,339일이며 주 분석은 2024년(366일)이다. 출발 시각은 7–9시와 17–19시가 20분 단위, 나머지는 1시간 단위이고, 본 연구는 시 단위로 합쳤다. 이동 목적은 출근, 등교, 귀가, 쇼핑, 관광, 병원, 기타 7종이다.

라벨의 성격. 서울 생활이동 안내 페이지에 따르면 목적은 통신 기록에서 야간 상주지(집), 주간 상주지(직장·학교), 기타 장소를 추정한 뒤 이들 사이의 이동 유형으로 판정한다. 끝점에서 27분 이상 머문 경우만 이동으로 센다. 따라서 출근·등교·귀가는 사실상 제공자의 규칙 라벨이며, 쇼핑·관광·병원이 어떻게 판정되는지는 확인하지 못했다. 내외국인 구분도 통신 가입 유형에 의존한다. 이 점 때문에 라벨 복원 성공은 “제공자의 분류를 흐름만으로 복원했다”까지만 뜻한다.

3.2 노드와 전처리

노드는 서울 행정동 426개(2024년 12월 기준), 경기·인천 시군구 54개, 그리고 나머지 지방을 합친 “기타지방” 1개로 총 481개이다. 서울 밖끼리의 이동(전체 흐름의 56.6%)은 연구 범위 밖이라 제외했고, 서울과 관련된 흐름이 남는다(2024년 전체 흐름의 43.4%). 하루를 평일(주말·공휴일 제외)과 주말·공휴일로 나누고, 1-9월(평일 184일, 주말 90일)을 학습에, 10-12월(평일 62일, 주말 30일)을 검증에 쓴다. 각 구간의 평균 하루 유량 텐서 $Y_{c,h,o,d}$ (c : 요일 유형, h : 시, o, d : 출발·도착 노드)를 모델의 대상으로 삼는다. 학습 구간의 서울 관련 일 유량은 평일 약 2,634만 건, 주말 약 2,108만 건이다.

행정구역 코드 처리. 행정동 코드가 기간 중 바뀐다. 2023-02에 강남구 일원2동(11680740)이 폐지되고 개포3동(11680675)이 신설되었으며, 2025-08에 동대문구 용신동(11230536)이 신설동(11230515)과 용두동(11230533)으로 분할되었다. 각각 하나의 노드로 합쳤다. 2023년에는 부천시가 단일 코드(41190000)로 기록되어 전체 흐름의 2.6%가 기타지방으로 들어가므로, 2023년 집계에서는 원미구 노드에 합쳤다. 또한 2025년 9월부터 파일 인코딩이 cp949에서 UTF-8로 바뀌어, 처음에는 이 기간(122일)의 내외국인 구분이 해석되지 않아 흐름이 통째로 제외되었다. 인코딩을 자동 판별하도록 고쳐 다시 집계했다.

3.3 외부 검증용 센서

생활이동과 측정 방식이 다른 두 계열을 쓴다. 서울 전체 시간별 지하철 승하차(교통카드)와 TOPIS 도로 검지기의 교통량(합)·속도(평균)이다. 일 단위로 합산해 쓴다. 버스 승차는 원자료가 월별 시간대 프로파일뿐이라 일별 변동이 없으므로 제외했다.

3.4 노드 위치

행정동 경계 폴리곤은 없어 지도 그림의 위치는 근사다. 서울 행정동 426개 중 360개는 이름이 겹치는 법정동 폴리곤의 중심으로, 나머지 66개는 소속 구 안에서 결정적으로 흩어 배치했다. 시군구 노드는 해당 폴리곤의 대표점이다. 이 위치는 그림에만 쓰이고 분석에는 쓰이지 않는다.

4 방법

4.1 잠재 동기 모델

동기 $k = 1, \dots, K$ 마다 출발지 분포 A_k , 도착지 분포 B_k (노드 위의 소프트맥스), 요일 유형별 하루 리듬 $T_{k,c}$ (24시간 위의 소프트맥스), 세기 $s_{k,c} > 0$, 거리 척도 $L_k > 0$ 를 둔다. 셀 (c, h, o, d) 의 기대

이동량은

$$\mu_{c,h,o,d} = \sum_{k=1}^K s_{k,c} T_{k,c,h} A_{k,o} B_{k,d} \exp(-\text{dist}_{od}/L_k). \quad (1)$$

관측 Y 에 대해 푸아송 음의 로그우도 $\sum(\mu - Y \log \mu)$ 를 최소화한다. 이 구조는 “어디 사는 사람이(A) 어디로(B) 언제(T) 얼마나 멀리(L) 가려 하는가”를 그대로 매개변수화하므로 각 요소의 의미를 읽을 수 있다.

거리. 행정동 경계가 없어 노드 사이 거리는 데이터의 평균 이동거리(이동 인구 가중)를 쓴다. 한 해 동안 관측되지 않은 쌍은 관측 거리로 만든 그래프의 최단 경로로 채웠다(Floyd-Warshall).

학습. 전체 배치 Adam(학습률 0.05에서 0.002까지 코사인 감쇠), 4,000 스텝, 시드 5개. $s_{k,c}$ 는 로그 스케일 매개변수로 두고 합계 유량이 맞도록 초기화한다. 이 매개변수화는 분석 중 오류를 발견해 고친 것이며 부록 A에 적었다. 모든 실험은 단일 GPU에서 한 모델당 수 초 내에 끝난다.

4.2 기준선

- B1: 정적 OD $\times$ 공통 시간곡선. $\mu = \text{OD}_c[o, d] \cdot P(h \mid c)$. 매개변수 462,770개로 OD별 규모를 그대로 외운다. 시간에 따른 방향 반전(아침 $A \rightarrow B$, 저녁 $B \rightarrow A$)은 표현하지 못한다.
- B2: 리듬 공유 모델. 같은 모델에서 모든 동기가 하나의 하루 리듬 T_c 를 공유한다. 동기마다 리듬이 달라야 하는지를 가른다.
- K=1 중력모형. 동기 하나.

4.3 평가 설계: 가설, 예상, 이유

학습 전에 정한 가설과 예상이다. 숫자는 근거가 있는 추측이었다.


모델 선택에는 (i) 검증 구간의 푸아송 편차(총 유량 대비), (ii) 시드 간 재현성(Hungarian 매칭 코사인 0.9 이상)을 쓰기로 했다. 시드 재현성 기준은 충족하지 못했다(5.1절).

	가설과 사전 예상	이유
H1	동기가 숨겨둔 목적 라벨을 복원한다. 출근·귀가는 순도 0.7 이상, 쇼핑·관광·병원 분리되지 않음. 목적 예측 정확도: 시간만 55% < 동기 65-70% < 지도학습 상한 75%.	제공자의 목적 규칙은 집·직장·기타 사이 이동이고, 모델의 출발·도착 분포가 같은 구조를 표현한다. 시간만으로는 8시 출근과 8시 기타 이동을 구별 못 한다.
H2	단기외국인 비중이 평균의 2배 이상인 동기가 있고, 명동·종로·이태원·홍대로 도착하며 아침 피크가 없다.	관광객은 고정된 집·직장이 없다. 내외국인은 회선 정보에서 오므로 이동 패턴으로 만든 라벨이 아니다.
H3	통근 동기의 일별 세기가 지하철 승하차와 상관 0.5 이상, 비통근 동기는 약하다.	서울 통근은 대중교통 비중이 높다. 통신과 교통카드는 측정이 독립이다.
H4	연휴에 통근 동기가 평소의 30% 이하로 줄고, 불꽃축제·집회일에 여의도 도착이 설명되지 않은 채 늘며, 폭설일 통근이 줄거나 늦어진다.	동기마다 탄력이 다르다. 성분을 고정하면 일회성 모임은 잔차로 남는다.
H5	통근 동기의 거리 척도가 가장 길고 등교·생활권이 가장 짧다. 귀가는 장·단거리 동기로 갈린다.	통근은 먼 거리를 감수하고 일상 불일은 가까워서 해결한다. 출근(4.4km)과 귀가(2.1km)의 중앙 거리가 비대칭이다.
H6	유량 상위 6개 동기는 해가 바뀌어도 코사인 0.8 이상으로 유지된다.	도시의 거주·업무 배치는 1년 사이 크게 바뀌지 않는다.

표 1 사전 가설과 예상.

5 결과

5.1 모델 성립과 K 선택



파란 띠는 시드 범위. 정적 기준선(점선)을 $K = 6$ 부터 따라잡고 $K = 8$ 에서 12% 낮다.

동기 6개와 정적 모델이 같은 검증 편차(0.298 대 0.299)에 이르며 파라미터는 76배 적다. $K = 8$ 에서는 12% 낮고(0.263), 파라미터는 57배 적다. 시간 리듬을 공유시킨 변형은 $K = 8$ 에서 0.387로 47% 나쁘고 $K = 16$ 에서 75% 나쁘다. 동기마다 하루 리듬이 달라야 한다는 것이 확인된다. 4,000 스텝은 완전한 수렴 전이다. 5배 길게(20,000 스텝) 학습하면 검증 편차가 $K = 8$ 에서 0.263에서

모델	파라미터	검증 편차 (최고 / 평균)	리듬 공유 변형
정적 OD × 공통 시간곡선 (B1)	462,770	0.299	
동기 $K = 1$ (중력모형)	1,013	2.004 / 2.005	—
$K = 2$	2,026	0.596 / 0.597	0.626
$K = 4$	4,052	0.385 / 0.387	0.448
$K = 6$	6,078	0.298 / 0.310	0.409
$K = 8$	8,104	0.263 / 0.268	0.387
$K = 12$	12,156	0.221 / 0.226	0.364
$K = 16$	16,208	0.200 / 0.205	0.350
$K = 32$	32,416	0.148 / 0.158	0.322
$K = 64$	64,832	0.123 / 0.131	0.312

표 2 동기 수에 따른 검증(10-12월) 푸아송 편차. 낮을수록 좋다. 시드 5개. 리듬 공유 변형은 최고값.

0.255로, $K = 16$ 에서 0.200에서 0.188로 3-6% 더 내려간다. 따라서 위 기준선 비교는 보수적이며, 이후 H1-H6 분석은 4,000 스텝 적합으로 수행해 길게 학습하면 세부 수치가 조금 달라질 수 있다.

편차는 K 에 따라 매끄럽게 내려가며 뚜렷한 꺾임이 없다($K = 4 \rightarrow 8$ 에서 가장 크게 떨어지고 이후 완만). 그래서 편차만으로는 K 를 정하지 못하고, 해석 가능성으로 $K = 8$ (대표)과 $K = 16$ (상세)을 골랐다.

K	매칭 코사인 평균	유량 가중	0.9 초과 동기 비율
4	0.83	0.83	0.50
6	0.80	0.81	0.38
8	0.77	0.78	0.22
12	0.76	0.79	0.31
16	0.74	0.78	0.28
32	0.71	0.74	0.14

표 3 시드 간 동기의 재현성(출발지·도착지·하루 리듬을 이어붙인 벡터의 Hungarian 매칭 코사인). 기준(0.9)을 어떤 K 에서도 충족하지 못한다.


시드 재현성은 기준 미달이다. 같은 구조가 대체로 재현되지만 개별 동기의 경계는 시드에 따라 합쳐지고 쪼개진다. 개별 동기의 해석은 예시로 읽어야 하고, 편차·예측력·센서 상관 같은 집계 지표가 더 믿을 만하다.

동기(해석)	유량 비중	평일 정점	실제 흐름 기준 출발 → 도착
퇴근 (도심→경기)	18.2%	18시	역삼1·여의·종로 → 남양주·고양 덕양·성남 분당
외곽 생활권	17.0%	8시 (주말 13시)	하남·고양·진관동 안
출근 (경기→도심)	12.6%	7시	남양주·분당·고양 → 역삼1·여의·종로
먼 길·관문	12.4%	9시 (주말 14시)	기타지방·공항동·반포4동 ↔ 인천 중구(인천공항)·반포4동
도심의 낮	11.4%	12시	종로·여의·한강로 안
외곽→도심 출근	11.2%	7시	세곡·진관·독산1 → 여의·역삼1·남양주
근거리 저녁 여가	8.8%	12시 (주말 19시)	역삼1·화양·사근 안
동네의 밤	8.3%	8시 (주말 21시)	신촌·서교·흑석 안

표 4 $K = 8$ 모델의 동기(시드 1, 학습 편차 최저). 상위 노드는 모델 매개변수 A, B 가 아니라 동기가 설명하는 실제 흐름의 합으로 구했다(A_k, B_k 는 거리 감쇠를 보정하느라 먼 노드에 가중치가 몰린다).


5.2 발견된 동기

그림 2. 동기별 하루 리듬 ($K=8$)



실선은 평일, 점선은 주말·공휴일. 퇴근과 출근은 평일 하루 리듬이 거울상이고, 먼 길·관문은 주말에 상대적으로 큰 동기다.

그림 3. 모델이 설명하는 이동 흐름의 시각별 스냅샷(기타 지방 제외), 선 색은 우세한 동기




모델이 설명하는 흐름. 평일 07시에는 금색·주황색(출근)이 도심으로, 18시에는 붉은색(퇴근)이 바깥으로 흐른다. 노드 위치는 근사.

가장 큰 동기들은 해석이 자연스럽다. 퇴근 동기와 출근 동기는 같은 도심 업무지구와 경기 도시들을 잇되 방향과 시각이 반대다. 먼 길·관문 동기(거리 척도 25.2km, 평균 OD 거리 42km)는 인천공항, 김포공항, 고속터미널 같은 장거리 거점을 중심으로 하며 평일보다 주말 세기가 1.32배 높다. 나머지 작은 동기는 신촌·서교, 역삼·화양처럼 한두 곳의 지역 단위 군집에 가깝다(거리 척도 0.2–1.2km).

5.3 H1: 숨겨둔 이동 목적의 복원

예측기 ($K = 16$, 10–12월, 흐름 가중)	교차엔트로피	정확도
최빈값(기타)	—	49.0%
동기만 (설계: 동기당 목적 구성 하나)	0.958	57.6%
시간만 $P(\text{목적} c, h)$	0.898	60.5%
시간 + 거리 구간	0.874	61.5%
동기 + 시간 $P(\text{목적} k, c, h)$ (추가)	0.862	62.1%
지도학습 상한 $P(p h, o, d)$	0.797	64.8%

표 5 동기가 숨겨둔 목적 라벨을 얼마나 예측하는가. “동기 + 시간”은 사전 설계에 없던 추가 변형이다(부록 A).



동기를 시간 정보 위에 얹으면 소폭 개선되지만 지도학습 상한에는 크게 못 미친다.

예상은 대체로 틀렸다. 설계대로(동기당 하나의 목적 구성) 평가하면 시간만 쓴 예측보다 나쁘다(57.6% 대 60.5%). 동기의 목적 구성을 시간과 무관하게 평균내면 시간 정보가 사라지기 때문이다. 이를 보완해 목적 구성을 시간대별로 두는 변형(동기 + 시간)을 추가했고, 이는 시간만(60.5%)과 시간+거리 구간(61.5%)을 넘어 62.1%에 이르지만 개선 폭은 작다. 시간만과 지도학습 상한 사이 격차의 약 36%($K = 8$ 은 28%)를 메우는 정도다. 순도는 출근 최고 0.55, 귀가 0.63과 0.56으로 예상(0.7)에 못 미친다. 쇼핑·관광·병원 등은 모든 동기에서 비중이 3% 미만(쇼핑 $\leq 2.4\%$, 관광 $\leq 0.7\%$, 병원 $\leq 0.8\%$)이라 분리되지 않았다. 이 셋은 전체 흐름의 0.1~0.4%라 우도에 거의 기여하지 못한다. 이 부분의 예상(분리되지 않음)은 맞았다. 해석상 한계로, 목적 라벨이 규칙 기반이므로 성공해도 제공자의 분류 복원이지만 실제 이유의 복원이 아니다.

5.4 H2: 외국인 동기

동기별 단기외국인 비중을 도시 평균(16.6%)으로 나눈 비는 $K = 8$ 에서 최대 1.25, $K = 16$ 에서 1.35, $K = 32$ 에서 1.52(흐름의 2.6%인 작은 동기)이며, 2배 이상은 없다. 가장 높은 것은 장거리·관문 동기다. 예상은 틀렸다.


원인을 점검하자 더 큰 사실이 나왔다. 단기외국인의 시간대별 흐름이 내국인과 거의 같다.

- 평일 시간대 분포 상관 0.976, 주말 0.997(장기외국인은 0.945, 0.979).
- 출근 시간대(7~9시) 점유율 19.2%(단기외국인) 대 20.6%(내국인), 퇴근(17~19시) 19.2% 대 21.1%.
- 주말·공휴일/평일 흐름 비는 0.82 대 0.80.
- 단기외국인이 하루 약 434만 건으로 전체의 16.5%이다.

통상적 의미의 관광객이라면 있을 수 없는 규모와 리듬이다. 이 집단은 거주자와 같은 일상 리듬을 가진 집단(예: 회선 유형으로 분류된 단기 체류 근로자·학생 등)일 가능성이 크다. 모델이 실패한 것이 아니라 라벨이 행동적으로 구분되지 않는다. 원인은 확인하지 못했고 제공자의 분류 기준 확인이 필요하다.

5.5 H3: 독립 센서와의 연동

동기 성분을 고정하고 날짜별 세기 $\lambda_k(\text{day})$ 만 푸아송 EM으로 추정한다. 같은 요일·같은 휴일 상태인 전후 28일(자기 제외)의 평균을 뺀 잔차끼리 피어슨 상관을 구했다.




동기 세기와 센서의 같은 요일 잔차 상관. 통근 동기가 지하철과 가장 강하게 연동한다.

통근 동기(퇴근 0.77, 출근 0.73, 외곽→도심 0.66)가 지하철과 가장 강하게 연동하고, 장거리·관문 동기(0.16)와 외곽 생활권(0.22)이 가장 약하다. 모든 동기를 합친 세기와의 상관은 0.59다. 도로 교통량과의 상관은 더 약하다(최대 0.53). 속도 평균은 음의 상관(-0.1~ -0.3)인데 혼잡할수록 느려지므로 방향은 정상이다. 공휴일을 제외하든 포함하든 결과가 같다. 예상은 맞았다: 통근 동기가 0.5 이상으로 연동하고 비통근 동기는 약하며, 장거리 동기가 지하철과 가장 무관한 것도 해석과 맞다. 통신과 교통카드는 측정이 독립이므로, 같은 날 같이 흔들린다는 것은 동기가 측정 잡음이 아닌 실제 행동이라는 증거다.

5.6 H4: 사건일

그림 6. 사건일과 연휴



(a) 사건일과 평범한 토요일의 여의동 초과 도착(관측 대비 모델 예상, 같은 요일 기준선). (b) 설·추석의 동기별 세기를 평소 평일로 나눈 값.

연휴. 설(2/10)과 추석(9/17)에 퇴근 동기는 평소 평일의 0.33/0.35, 외곽→도심 출근 동기는 0.52/0.50으로 내려가지만, 경기→도심 출근 동기는 0.99/0.95로 거의 그대로다. 이 동기에는 연휴 중 도심 방문 이동이 섞인 것으로 추정되나 확인하지 않았다. 장거리·관문 동기는 1.85/1.59배로 증가한다. 예상한 “통근 동기 30% 이하”는 맞지 않았다(줄어들 동기도 약 1/3-1/2이고 한 동기는 줄지 않았다). 통근 일부는 줄고 장거리 이동은 늘어난다는 큰 그림만 맞았다.

불꽃축제와 집회. 평소 세기로 계산한 예상 대비 도착 동별 초과를 보면, 서울세계불꽃축제(10/5)에서 여의동 +237,074건(+44%), 한강변의 노량진1동 +55%, 이촌2동 +86%, 이촌1동 +58%가, 여의도 집회가 있던 12/7과 12/14에는 여의동 +281,452건(+49%), +372,740건(+56%)이 가장 크다. 반면 평범한 토요일(11/9, 12/21)에는 여의동이 오히려 -23%, -32%이다. 사건의 영향은 동기의 일별 세기로는 거의 보이지 않고(집회일 $|z| \leq 1.8$) 도착지 잔차로만 드러난다. 성분을 고정하면 일회성 모임이 모델 밖으로 밀려나 잔차가 된다는 설계의 논리가 맞았다. 예상은 맞았다.

폭설과 비상계엄. 폭설(11/27-28)에서 통근 동기는 평소의 0.85-1.01로 거의 변하지 않고, 장거리·관문 동기가 0.79-0.80으로 가장 크게 줄었다. 예상한 통근 지연은 뚜렷하지 않았다. 12/3 비상계엄 선포일에는 동기 세기에도 도착 잔차에도 뚜렷한 신호가 없다(모든 $|z|$ 가 약 2 이내). 예상(사건이 하루 단위 흐름에 남는다)은 틀렸다. 선포가 밤에 있었던 만큼 시간대별 분석이 필요할 수 있으나 확인하지 않았다.

예상하지 못한 발견: 사실상 쉬는 날. 공식 휴일이 아닌데 통근 동기가 무너진 날이 있다. 5/1 근로자의 날(외곽→도심 출근 -44.6σ , 퇴근 -26.5σ), 6/7 현충일 다음 날(외곽→도심 출근 -11.4σ), 9/30(10/1 임시공휴일 전날, -14.2σ), 12/29-31 연말이다. 모델이 달력 정보 없이 “사실상의 휴일”을 찾아낸다.

주의. 금천구 가산동은 사건일과 대조일을 가리지 않고 모든 토요일에 $-53 - -71\%$ 로 나온다. 사건 효과가 아니라 모델 적합 오류로 보이며 원인은 확인하지 않았다. 사건 신호는 양(+)의 잔차 쪽에서 읽는 것이 안전하다.

5.7 H5: 거리 척도

거리 척도는 동기마다 0.2km에서 25km까지 넓게 퍼진다($K = 8$: 0.2, 0.3, 0.9, 1.2, 5.2, 5.5, 8.0, 25.2km). 귀가는 예상대로 장거리와 단거리로 갈린다. $K = 16$ 에서 도심→경기 장거리 귀가(척도 7.9km, 평균 OD 11.9km)와 홍대·압구정에서 경기·인천으로 가는 심야 귀가(1.8km, 4.3km, 평일 정점 21시)가 따로 나오며, $K = 32$ 에서는 귀가 동기 척도가 0.9, 3.7, 7.8, 13.7km로 갈린다. 실제 이동거리 중앙값이 출근 6.3km, 귀가 3.9km로 비대칭인 것(거리 구간 히스토그램 근사, 서울 밖 흐름 포함)은 “귀가 = 직장→집 + 근처→집의 혼합”이라는 설명과 맞는다. 다만 가장 긴 척도는 통근이 아니라 공항·터미널 이동(25km)이고 통근 동기는 7-8km였다. 등교는 어떤 K 에서도 따로 분리되지 않았다(등교 비중 최대 0.04). 예상은 부분적으로 맞았다.

5.8 H6: 연도 간 안정성

$K = 8$ 을 연도별로 독립적으로 학습하고(시드 5개, 학습 편차 최저), Hungarian 매칭으로 2024년 모델과 비교했다. 또한 2024년 성분을 재학습 없이 다른 해의 하루 평균 유량에 적용한 편차를 잰다. 2023년은 예상대로다. 8개 중 5개 동기가 0.97–1.00으로 거의 같고, 유량으로 가중한 코사인

	2023	2025
매칭 코사인 평균 (유량 가중)	0.869 (0.899)	0.747 (0.754)
참고: 2024 안 시드끼리($K = 8$)	0.767 (0.780)	
편차: 2024 성분을 재학습 없이 적용 (8천 파라미터)	0.261	0.241
편차: 그 해 데이터로 재학습한 동기 모델	0.229	0.230
편차: 그 해 데이터로 직접 맞춘 정적 OD×시간 (46만)	0.267	0.258
편차: 2024로 추정된 정적 OD×시간을 적용	0.306	0.277

표 6 해를 넘어서는 동기의 안정성. 편차는 해당 연도 전체 평균 하루 유량에 대한 값이다.

0.90이다. 2025년은 0.75로 한 개만 거의 일치하는데, 같은 해 안에서 시드끼리 비교한 값(0.77)과 비슷해서 구조 변화인지 시드 잡음인지 이 방법으로는 구분되지 않는다. 판정을 보류한다. 더 강한 증거는 편차에 있다. 2024년 성분을 그대로 가져다 써도 다른 해 유량을 그 해 데이터로 직접 맞춘 46만 파라미터 정적 모델보다 낮은 편차로 설명한다(2023: 0.261 대 0.267, 2025: 0.241 대 0.258). 재학습·정적 모델은 해당 연도 데이터에 맞춘 표본 내 값이고 2024 성분 적용만 표본 밖이라 후자가 불리한 비교인데도 앞선다는 점이 근거다.


5.9 부수 관측: 2023–2026년 출근 거리는 늘지 않았다

서울 집값이 오르며 출퇴근이 더 멀어졌는가라는 물음을 같은 데이터로 점검했다. 출근 목적, 내국인, 화·수·목요일만 모아 월별 중앙값을 구하고, 같은 달끼리 비교해 계절성을 제거했다(1–8월 평균). 출발 또는 도착이 서울인 이동이다.

	2023	2024	2025	2026
출근 평균 거리 (km)	11.11	11.07	10.93	10.88
중앙값 거리 (km)	7.90	7.83	7.66	7.59
20 km 이상 비중	16.1%	16.1%	15.8%	15.8%
평균 소요시간 (분)	48.9	49.2	48.6	48.9
60분 이상 비중	31.2%	31.7%	31.4%	32.2%
서울 출근 중 경기·인천 출발 비중	26.2%	26.2%	25.8%	25.7%
경기·인천→서울 평균 거리 (km)	21.0	21.0	21.0	21.0

표 7 출근 이동의 1–8월 평균.

그림 7. 출근 이동의 월별 추이 (화·수·목 중앙값, 내국인)



월별 추이. 평균 거리는 소폭 줄고 있고 장거리 비중과 외부 출발 비중은 사실상 평평하다.

계절성을 뺀 추세는 평균 거리 연 -0.8% , 20km 이상 비중 연 -0.9% 이다. 늘어난 증거는 없다. 60분 이상 비중만 2026년에 31.4%에서 32.2%로 소폭 올랐으나 평균 시간은 같아 잡음일 수 있다. 이 결과를 “집값은 출퇴근 거리에 영향이 없다”로 읽어서는 안 된다. 기간이 3.6년으로 짧고(이사에 따른 출근거리 변화는 서서히 반영될 수 있다), 이 데이터에는 집값이 없어 관계를 검증할 수 없다. 출근 라벨도 야간·주간 상주지를 추정된 규칙이다. 출근 건수가 2023–2025년에 4.7% 늘었는데 실제 증가인지 보정 변화인지 알 수 없어 건수보다 상대 지표를 신뢰했다.

5.10 예비 실험: 일 단위 자동인코더 임베딩

이 방향을 택하기 전에, OD쌍의 하루 24시간 프로파일을 변분 자동인코더(잠재 16차원)로 압축하고 OD별 연중 평균을 임베딩으로 삼아 클러스터링하는 실험을 했다(OD 상위 2만 쌍, 2024년, OD별로 규모를 표준화한 “모양만” 버전). 복원 오차는 OD별 평균 프로파일 기준선보다 훨씬 낮았고(0.022 대 0.323), 2023년 같은 OD의 임베딩 코사인은 0.855였다(2024년 상반기와 하반기끼리 0.860). 임베딩은 왕복 OD가 닮는 정도에서만 평균 프로파일보다 낮고(같은 16차원인 PCA의 2배), 연도 간

특징	A→B와 B→A 코사인	연도 간 클러스터 일치	ARI	출발 구 예측	도착 구 예측
임베딩 (16차원)	0.203	0.816	0.624	0.121	0.122
평균 프로파일 PCA16	0.105	0.794	0.551	0.131	0.145
평균 프로파일 48차원	0.040	0.872	0.709	0.155	0.173
다수결 기준선	0	—	—	0.095	0.098

표 8 임베딩과 평일·주말 평균 프로파일(규모 표준화)의 비교.

안정성과 지리 정보에서는 원본 프로파일이 더 낮거나 같았다. 즉 이 임베딩은 평균 패턴의 요약에 가까웠다. 하루 단위 패턴을 압축하면 평균을 내는 순간 날마다 같이 움직이는 구조가 사라진다. 이것이 흐름 전체를 동기로 분해하는 지금의 접근으로 방향을 바꾼 이유다.

	맞은 예상	틀린 예상
모델	$K \approx 6-10$ 에서 정적 기준선을 이긴다. 리듬 공유가 훨씬 나쁘다. 2023년으로 일반화된다.	시드 재현성 0.9. 2025년 유지(보류).
H1	쇼핑·관광·병원은 분리되지 않는다.	동기만으로 65-70%. 순도 0.7.
H2	—	단기외국인 2배 이상 동기(라벨 자체가 거주자형 리듬).
H3	통근 동기와 지하철 상관 ≥ 0.5 , 장거리 동기는 무관.	—
H4	연휴의 퇴근·외곽→도심 출근 동기 감소(약 $1/3-1/2$)와 장거리 증가, 불꽃축제·집회의 여의동 초과.	연휴 통근 30% 이하(경기→도심 동기는 줄지 않음), 폭설의 뚜렷한 통근 지연, 계엄일 신호.
H5	귀가의 장·단거리 분리, 거리 척도의 다양성.	통근 동기의 거리 척도가 가장 김.
H6	2023과 상위 동기 일치.	—

표 9 사전 예상과 결과.

6 논의

6.1 예상 대비 정리

예상하지 못한 것은 단기외국인의 거주자형 리듬, 공식 휴일이 아닌 쉬는 날의 탐지, 가산동의 토요일 적합 오류였다.

6.2 해석

잠재 동기는 이동량만으로 안정적인 큰 구조를 학습하고, 그 구조는 독립 센서와 사건일에서 의미 있는 신호를 낸다. 동기마다 하루 리듬이 달라야 한다는 것은 가장 분명한 결과다. 반대로 제공자의 목적 라벨은 동기가 시간 정보에 더해 아는 것이 많지 않았다. 목적이 시간, 출발·도착 지역, 거리로 이미 대부분 결정되고 남은 설명력을 모델이 더 얻지 못했거나, 제공자의 라벨이 우리 모델이 보는 구조 밖의 정보(도착지의 성격, 개별 이력)를 쓰기 때문일 수 있다. 어느 쪽인지는 가리지 못했다.

6.3 한계

1. 개별 동기는 시드에 민감하다(재현성 0.74-0.83). 큰 동기 몇 개는 안정적이고 작은 동기는 지역 군집에 가깝다.
2. 목적·내외국인 라벨은 제공자의 추정이다. 라벨 복원은 실제 이유의 복원이 아니다.
3. 모델은 하루 평균 구조만 본다. 사건 효과는 성분 밖 잔차로만 드러난다.
4. $K = 8-16$ 은 편차가 계속 내려가는 구간이라 동기 수의 정답은 없다. 학습은 4,000 스텝으로 완전한 수렴 전이다(5.1절).
5. 서울 밖 노드는 시군구 단위로 거칠고, 서울 밖끼리의 흐름(56.6%)은 제외했다.
6. 노드 위치가 근사이므로 지도 그림은 질적 설명용이다.

7. 출근 거리 추세는 집값과의 관계를 검증하지 못하며 기간이 짧다.

7 결론

시간대별 행정동 OD 흐름은 소수의 잠재 동기가 중력형 공간 구조와 각자의 하루 리듬으로 만들어진 흐름으로 잘 설명된다. 동기 6-8개가 46만 파라미터의 정적 모델과 같거나 더 낮고, 그 동기의 세기는 교통카드와 같은 날 같이 움직이며, 알려진 사건이 있던 날 모델이 설명하지 못하는 초과 도착이 바로 그 장소에 나타난다. 반면 이 동기들이 제공자의 목적 분류를 얼마나 복원하는지는 시간대만 쓴 예측을 소폭 넘는 데 그쳤고, 외국인 라벨은 행동적으로 구분되지 않았다. 앞으로는 수단 OD(지하철 흐름을 실제 승하차와 맞추는 독립 검증)와 연령 데이터를 더해 라벨 의존을 줄이고, 시간대별 사건 분석과 동기 수의 선택 기준을 정교하게 하는 것이 과제다.

A 설계 대비 변경과 정정 이력

1. 세기 매개변수 오류. 첫 스왑에서는 세기 $s_{k,c}$ 를 softplus로 두었는데 값이 수천만 단위여서 학습률 0.05의 Adam으로는 사실상 움직이지 못했다. 모든 동기의 주말/평일 세기 비가 초기값(0.80)으로 같았던 것이 단서였다. 동기의 크기가 사실상 고정되어 작은 지역 동기가 “볼륨이 굵는” 상태가 되었고, 그 결과 $K = 16$ 에서도 정적 기준선을 못 이겨(0.42 대 0.30) 사전 정한 멈춤 조건에 걸리는 것처럼 보였다. 로그 스케일로 고친 뒤 $K = 6$ 부터 이긴다. 오류 버전은 별도 이름으로 보관했고, 본문 수치는 모두 정정 후 값이다.
2. H1 변형 추가. 설계에 없던 “동기 + 시간” 예측기를 추가했다. 설계 방식은 시간 정보를 버려 시간만 쓴 기준선보다 구조적으로 불리하기 때문이다. 표에는 설계 방식과 추가 변형을 모두 실었다.
3. 동기 카드의 노드. 모델 매개변수 A_k, B_k 대신 동기가 설명하는 실제 흐름의 합으로 상위 출발·도착 노드를 구했다.
4. 사건일 기준선. 처음에는 토·일을 섞은 기준선을 써서 토요일 효과가 새어 들어갔다. 같은 요일 기준선으로 바꾸고 평범한 토요일을 대조군으로 넣었다. 공휴일은 같은 요일 기준선이 부족해 평소 평일 대비 비로 보고했다.
5. 데이터. 2025-09 이후 파일의 인코딩 변경, 2023년 부천 코드, 행정동 코드 분할·교체는 3.2절에 적었다. 2023년 시험 중 2024년 $K = 8$ 적합 파일이 덮어쓰지는 실수가 있어 연도별 저장 위치로 코드를 고치고 2024년 $K = 8$ 을 다시 학습했다. 시드별 검증 편차(0.2634 등), 평균(0.2677), 학습 편차가 가장 낮은 시드가 이전 값과 일치하는 것을 확인해 이후 분석과 정합성을 유지했다.

B 재현

분석 코드는 `uve_experiment/od_embedding/` 아래에 있다. `agg_labels.py` YEAR(일별 zip을 집계), `fit_motives.py` Ks NSEED(모델 학습, 연도는 환경변수 YEAR), `eval_motives.py` K(H1, H2, H5), `daily_motives.py` K와 `h3h4.py` K(H3, H4), `stability.py`와 `h6.py`(재현성, H6),

commute_trend.py(출근 거리 추이). 결과 요약은 RESULTS_latent_will.md, 데이터 정리는 DATA_NOTES.md에 있다. 학습은 PyTorch, 시드 0-4, 4,000 스텝, 전체 배치이다.

참고문헌

- [1] L. Alexander, S. Jiang, M. Murga, M. C. Gonzalez. Origin – destination trips by purpose and time of day inferred from mobile phone data. *Transportation Research Part C* 58, 240 – 250, 2015.
- [2] D. M. Blei, A. Y. Ng, M. I. Jordan. Latent Dirichlet allocation. *Journal of Machine Learning Research* 3, 993 – 1022, 2003.
- [3] F. Calabrese, G. Di Lorenzo, L. Liu, C. Ratti. Estimating origin – destination flows using mobile phone location data. *IEEE Pervasive Computing* 10(4), 36 – 44, 2011.
- [4] M. C. Gonzalez, C. A. Hidalgo, A.-L. Barabasi. Understanding individual human mobility patterns. *Nature* 453, 779 – 782, 2008.
- [5] S. Han 외. Urban Vibrancy Embedding and Application on Traffic Prediction. arXiv:2602.21232, 2026.
- [6] S. Jiang 외. The TimeGeo modeling framework for urban mobility without travel surveys. *PNAS* 113(37), E5370 – E5378, 2016.
- [7] D. D. Lee, H. S. Seung. Learning the parts of objects by non-negative matrix factorization. *Nature* 401, 788 – 791, 1999.
- [8] T. Louail 외. From mobile phone data to the spatial structure of cities. *Scientific Reports* 4, 5276, 2014.
- [9] A. G. Wilson. A family of spatial interaction models, and associated developments. *Environment and Planning* 3(1), 1 – 32, 1971.
- [10] G. K. Zipf. The P1P2/D hypothesis: on the intercity movement of persons. *American Sociological Review* 11(6), 677 – 686, 1946.